

**Автономная некоммерческая организация высшего образования
«Университет Иннополис»**

**АННОТАЦИЯ
НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ
(БАКАЛАВРСКУЮ РАБОТУ)
ПО НАПРАВЛЕНИЮ ПОДГОТОВКИ
09.03.01 «Информатика и вычислительная техника»**

**НАПРАВЛЕННОСТЬ (ПРОФИЛЬ) ОБРАЗОВАТЕЛЬНОЙ ПРОГРАММЫ
«Анализ данных и искусственный интеллект»**

Тема	Использование памяти и графов знаний для оценки действий интеллектуальных агентов
-------------	--

Выполнил

Пател Кхуш Прадипбхай	
------------------------------	--

	ПОДПИСЬ
--	---------

Оглавление

Обновите это поле, чтобы сформировать оглавление.

Введение

Большие языковые модели применяются не только для генерации текста, но и для его оценивания в парадигме «языковая модель в роли судьи». Стандартный судья односторонний: он оценивает каждый пример изолированно и ничего не запоминает. Подключение к судье постоянной памяти потенциально позволяет переиспользовать прошлые оценки, однако та же память может распространять прошлые ошибки и приводить к утечке информации между связанными примерами. Цель работы — спроектировать, реализовать и строго оценить такую систему и определить, при каких условиях память действительно повышает качество оценивания. Научная новизна состоит в разработанном протоколе оценивания без утечек данных, в двухуровневом аудите замороженной памяти с криптографическим отпечатком SHA-256, и в корректирующем эмпирическом результате, опровергающем правдоподобный, но необоснованный вывод о пользе памяти.

Краткое описание основной части

Проблема. Память, подключённая к судье, может улучшать оценивание, но также может порождать утечку данных между связанными примерами; неаудируемый стенд оценивания может сообщать как о несуществующем выигрыше, так и о несуществующем падении точности.

Решение. Система MCTS-MAJ состоит из судьи с памятью, поискового судьи на основе дерева Монте-Карло и модуля поискового извлечения; память хранится в графовой базе Neo4j с пятью типами узлов и типизированными связями. Разработан протокол оценивания без утечек данных, закрывающий два канала: разбиение данных по вопросам и замораживание памяти на время теста. Реализован двухуровневый аудит замороженной памяти: детерминированный снимок состояния «до и после» с отпечатком SHA-256 и перехват во время выполнения всех операций записи. Аудит уже на этапе разработки выявил реальный дефект утечки, который был исправлен. Точность сопровождается доверительным интервалом Уилсона; сравнения

режимов выполняются на парных данных с точным критерием Макнемара и парным бутстрэп-интервалом.

Результаты. Эксперименты используют открытый набор данных EvalsBench (160 примеров, 80 уникальных вопросов, сбалансированное распределение проходных и непроходных ответов). При обычном протоколе память создавала видимость выигрыша порядка шести-десяти процентных пунктов. При аудируемом протоколе на 80 отложенных примерах для модели GPT-4o точность однопроводного судьи составила 70,0 %, судьи с памятью 65,0 %, поискового судьи 70,0 %, объединённого режима 71,8 %; все доверительные интервалы перекрываются, ни одно различие не значимо. Эталонная память с истинными метками не превосходит самостоятельно сформированную. «Отравление» памяти не вызывает значимого снижения точности; ранее наблюдавшийся обвал до 21,2 % оказался артефактом: сетевой сбой засчитывал ошибочные запросы как неверные ответы, и исправление обработки ошибок полностью устранило этот эффект.

Заключение

В работе спроектирована и реализована система MCTS-MAJ; разработан протокол оценивания без утечек данных и двухуровневый аудит замороженной памяти. При обычном протоколе память создавала видимость значительного выигрыша; при аудируемом протоколе этот выигрыш не подтверждается. Кажущееся резкое падение точности при «отравлении» памяти оказалось артефактом измерения. Защищаемый вклад работы является методологическим: разбиение по вопросам, замороженная память и двухуровневый аудит образуют протокол, доказывающий отсутствие утечки данных. На данном наборе данных как кажущаяся польза, так и кажущаяся хрупкость памяти в значительной мере являются артефактами протокола оценивания. Направления дальнейшей работы: расширение набора данных, применение аудируемого протокола к более слабым и более сильным моделям-судьям, оформление протокола и аудита как самостоятельного инструмента.

Список использованной литературы

1. L. Zheng et al., “Judging LLM-as-a-judge with MT-bench and chatbot arena,” NeurIPS Datasets and Benchmarks, 2023.
2. J. Gu et al., “A survey on LLM-as-a-judge,” arXiv:2411.15594, 2024.
3. P. Lewis et al., “Retrieval-augmented generation for knowledge-intensive NLP tasks,” NeurIPS, 2020.
4. Z. Zhang et al., “A survey on the memory mechanism of LLM-based agents,” arXiv:2404.13501, 2024.
5. W. Zou, R. Geng, B. Wang, and J. Jia, “PoisonedRAG,” USENIX Security, 2024.
6. S. Balloccu et al., “Leak, cheat, repeat: Data contamination and evaluation malpractices in closed-source LLMs,” EACL, 2024.